Doctorado en Informática – UTN FRRe/UNNE/UNAM

Curso: Introducción al Aprendizaje de Máquina

Trabajo Integrador

1. Opción elegida

Aplicación de Aprendizaje de Máquina + Informe final (trabajo grupal).

2. Integrantes: Stella Maris Gerzel, Gustavo Ebel, Juan Manuel Goya

3. Cronograma y tareas de los integrantes

Fecha	Actividad	Responsable
22 al 24 junio	Definición de/los problemas, optimización del dataset y alta del repositorio Git.	Todo el equipo
25 al 30 junio	Entrenamiento de los modelos. Revisión cruzada entre integrantes.	Todo el equipo
1 al 3 julio	Redacción del informe final del trabajo.	Todo el equipo
4 julio	Entrega del tabajo.	Todo el equipo

4. Herramientas

- Python 3, Google Colab.
- GitHub como repositorio de control de versiones. Se propone la siguiente organización:
  - Rama main: versión estable e integrada del proyecto.
  - Ramas de trabajo por funcionalidad (a definir en grupo), con merges periódicos hacia main.
  - Carpetas: /data, /notebooks, /src, /informe.

5. Resultados esperados

- Un conjunto de modelos de clasificación entrenados y comparados sobre el dataset seleccionado.
- Identificación de las variables con mayor influencia sobre el riesgo académico.
- Un informe final con metodología, resultados, métricas de evaluación y conclusiones.
- Código fuente documentado y disponible en el repositorio del proyecto.

6. Contexto y Problemática

El riesgo de bajo rendimiento académico y la deserción en los primeros años de la educación superior constituyen desafíos estructurales que afectan la equidad educativa, la eficiencia institucional y el desarrollo socioeconómico. Diversos estudios señalan que el desempeño en el primer año, especialmente en asignaturas introductorias de programación, es un factor determinante en la persistencia estudiantil (Bernardo et al., 2016; Bennedsen & Caspersen, 2019). Asimismo, la falta de mecanismos de detección temprana suele derivar en intervenciones tardías e ineficaces (Seymour & Hunter, 2019).

En este contexto, la creciente disponibilidad de datos educativos ha impulsado el desarrollo de la Minería de Datos Educativa (EDM) y el Learning Analytics (LA), disciplinas orientadas a la generación de conocimiento a partir de datos para mejorar los procesos de enseñanza y aprendizaje (Romero & Ventura, 2020). La literatura reciente destaca el uso de técnicas de aprendizaje automático para modelar la complejidad del rendimiento académico, superando enfoques estadísticos tradicionales (Kotsiantis, 2012). En particular, estudios previos han demostrado la efectividad de estas técnicas para la predicción del abandono y del desempeño académico a partir de variables académicas y contextuales (Cortez & Silva, 2008; Dekker et al., 2009), así como la necesidad de integrar dimensiones socioeconómicas y actitudinales en el análisis ((La Red Martínez et al., 2016); Albreiki et al., 2021; Baashar et al., 2022).

En este marco, el presente trabajo propone un sistema de predicción temprana del riesgo de bajo rendimiento académico en estudiantes de Ingeniería en Sistemas de la Universidad Nacional del Chaco Austral (UNCAus), basado en un repositorio que integra variables académicas, socioeconómicas, laborales y actitudinales. Las principales contribuciones de este trabajo son la construcción de un dataset contextualizado y el desarrollo de modelos de aprendizaje automático orientados a la detección temprana de estudiantes en riesgo académico.

6.1 Definición de los Problemas de Clasificación

Con el propósito de analizar diferentes manifestaciones del riesgo académico se definieron tres problemas de clasificación binaria: **Problema 1:** Riesgo académico global (A vs R+U). Clase 0: estudiantes aprobados (A). Clase 1: estudiantes desaprobados o ausentes/abandonaron (R+U). **Problema 2:** Riesgo de desaprobación (A vs R). Clase 0: estudiantes aprobados (A). Clase 1: estudiantes desaprobados (R). **Problema 3:** Riesgo de ausencia o abandono (A vs U). Clase 0: estudiantes aprobados (A). Clase 1: estudiantes ausentes o abandonaron la asignatura (U).

Esta estrategia permite estudiar separadamente los factores asociados al bajo rendimiento académico y aquellos vinculados específicamente al abandono.

6.2 Tarea de Machine Learning que se aborda

Se propone el entrenamiento de modelos supervisados de clasificación binaria de aprendizaje automático orientados a detectar estudiantes en riesgo académico en las asignaturas Algoritmos y Estructuras de Datos y Sistemas y Organizaciones, correspondientes al primer año de la carrera de Ingeniería en Sistemas de la Universidad Nacional del Chaco Austral (UNCAus), a partir de variables académicas, socioeconómicas, familiares, laborales, tecnológicas y motivacionales relevadas institucionalmente mediante el sistema académico SIU-Guaraní. El estudio utiliza información correspondiente a 978 registros académicos de las asignaturas Algoritmos y Estructuras de Datos y Sistemas y Organizaciones de las cohortes 2024 y 2025, lo que permite trabajar sobre un caso real e institucional en lugar de un dataset público genérico.

7. Objetivos

7.1 Objetivo general

El objetivo consiste en desarrollar modelos predictivos capaces de anticipar situaciones de desaprobación y abandono en los primeros años de la carrera de Ingeniería en Sistemas de la Universidad Nacional del Chaco Austral (UNCAus), a partir de variables académicas y contextuales disponibles de forma temprana en el ciclo lectivo.

7.2 Objetivos específicos

- Realizar un análisis exploratorio de datos (EDA) sobre el dataset unificado de UNCAus.
- Aplicar procesos de limpieza, codificación de variables categóricas y tratamiento de valores faltantes.
- Entrenar y comparar tres algoritmos supervisados ampliamente utilizados en problemas de clasificación: Regresión Logística, Random Forest y XGBoost. La selección de estos modelos responde a su capacidad para manejar conjuntos de datos heterogéneos, variables categóricas y relaciones no lineales entre atributos.
- Evaluar la necesidad de utilizar estrategias de balaceo de clases.
- Validar los modelos mediante validación cruzada estratificada, utilizando como métrica principal el área bajo la curva ROC (ROC-AUC). Adicionalmente calcular las métricas de: accuracy, precisión, recall y F1-score.
- Analizar distintos umbrales de decisión para estudiar el compromiso entre sensibilidad y cantidad de falsos positivos.
- Documentar el proceso y los resultados en un informe final.

8. Metodología

El trabajo adopta un enfoque cuantitativo basado en técnicas de Minería de Datos Educativa (Educational Data Mining, EDM) y aprendizaje automático para la identificación temprana de estudiantes en riesgo académico. El objetivo consiste en desarrollar modelos predictivos capaces de anticipar situaciones de desaprobación y abandono en los primeros años de la carrera de Ingeniería en Sistemas de la Universidad Nacional del Chaco Austral (UNCAus).

8.1 Descripción de datos:

Los datos son del tipo tabular y provienen de información correspondiente a las asignaturas Algoritmos y Estructuras de Datos y Sistemas y Organizaciones durante las cohortes 2024 y 2025. Por contener información académica y contextual de estudiantes, el dataset no se publica de manera abierta. El repositorio está compuesto por 978 registros de estudiantes, que integra 128 variables provenientes del relevamiento institucional mediante el sistema académico SIU-Guarani. Las variables consideradas abarcan dimensiones: socioeconómicas; familiares; laborales; tecnológicas; motivacionales y académicas.

Entre las variables incluidas se encuentran cobertura de salud, tipo de vivienda, situación laboral, convivencia familiar, acceso a recursos tecnológicos, práctica deportiva, recepción de becas y motivaciones para la elección de la carrera.

La variable objetivo es la variable nota, la cual contiene tres categorías. En la Tabla 1 se aprecia su distribución.

Tabla 1: Distribución de la variable de estudio

Categoría	Significado	Cantidad	Percentaje
A	Aprobado	279	28,5%
R	Desaprobado	451	46,1%
U	Ausente / abandonó	248	25,4%
Total		**978**	**100%**

Esta distribución muestra que el conjunto de datos presenta una proporción mayor de estudiantes desaprobados o ausentes/abandonó que aprobados. Por lo tanto, para el problema de riesgo académico global (A vs R+U), y para el problema de riesgo de desaprobación (A vs R) se puede observar existe un desbalance entre clases.

8.2 Distribución de clases para los problemas de clasificación

A partir de la variable nota, se definieron tres problemas binarios, en la Tabla 2 se muestra la distribución de clases para los tres problemas de clasificación:

Tabla 2: Distribución de claseclase

Problema	Clase 0	Clase 1	Clase 0 %	Clase 1 %	Total
A vs R+U	A = 279	R+U = 699	28,50%	71,50%	978
A vs R	A = 279	R = 451	38,20%	61,80%	730
A vs U	A = 279	U = 248	52,90%	47,10%	527

8.3 Tipos de datos

Durante el análisis del dataset fueron identificadas 125 variables de diferente naturaleza, la Tabla 3 muestra los tipos de variables que contiene el conjunto de datos.

Tabla 3: Tipos de variables de variables

Tipo de variable	Cantidad aproximada
Categóricas	84
Numéricas discretas / ordinales	21
Numéricas por formato	3
Texto o alta cardinalidad	7
Sin datos registrados	10
Total	**125**

Existen variables numéricas, como alumno, procedencia_localidad o procedencia_codigo_postal, que no deben interpretarse necesariamente como variables cuantitativas continuas, ya que funcionan como identificadores o códigos.

8.4 Valores Faltantes

El análisis de valores faltantes se realizó considerando como faltantes únicamente las celdas vacías y aquellas codificadas con los caracteres "-" o "_". Los valores cero no fueron considerados faltantes, dado que en distintas variables representan respuestas válidas o códigos registrados. Bajo este criterio, el dataset tiene 978 filas × 125 columnas =122.250 celdas, de las cuales 24.549 contienen valores faltantes, representando un 20.08%.

En la Tabla 4, se muestra las variables con mayor cantidad de valores faltantes, en la que puede observarse que 84 de las 125 variables no presentan valores faltantes, mientras que 10 variables se encuentran completamente vacías. Estas últimas corresponden principalmente a campos condicionales o descriptivos asociados a apoyos específicos, discapacidad o información adicional. Asimismo, 12 variables presentan entre 90% y 99% de valores faltantes, las que serán evaluadas cuidadosamente antes del entrenamiento de los modelos predictivos, ya sea para su exclusión, recodificación o tratamiento específico.

Tabla 4: Valores faltantes por variables

Variables	Faltantes	% sobre 978 registros
mot_apoyo_aula	978	100,00%
mot_otros_apoyos	978	100,00%
aud_comunicacion_otra	978	100,00%
aud_otros_apoyos	978	100,00%
aud_apoyo_vida_diaria	978	100,00%
vis_otros_apoyos	978	100,00%

psi_descripcion	978	100,00%
psi_apoyo_vida_diaria	978	100,00%
psi_otros_apoyos	978	100,00%
otra_apoyo_vida_diaria	978	100,00%
informacion_importante	975	99,69%
mot_apoyo_vida_diaria	975	99,69%
vis_apoyo_vida_diaria	972	99,39%
otra_descripcion	969	99,08%
costeo_estudios_descripcion	967	98,88%
nivel_idioma_otro	953	97,44%
idioma_otro	951	97,24%
trabajo_tarea_descripcion	909	92,94%
trabajo_carrera	892	91,21%
trabajo_hora_sem	892	91,21%
trabajo_ocupacion	884	90,39%
trabajo_hace	884	90,39%

8.5 Preparación de los datos

Al determinar las características del dataset, se decidió realizar una depuración inicial del conjunto de datos antes de iniciar con el análisis exploratorio de variables predictoras, la depuración consistió en la normalización de valores faltantes, eliminación de espacios en blanco y eliminación de espacios al inicio y al final de los valores. La depuración completa para la etapa de modelado se realizó posteriormente dentro del pipeline de trabajo.

8.6 Análisis Exploratorio

Con el objetivo de caracterizar la información disponible antes del entrenamiento de los modelos, identificar la naturaleza de cada atributo y evaluar su posible relación con la variable objetivo realizó un análisis de variables predictoras. En éste análisis no se consideraron las variables completamente vacías, es decir, las columnas que fueron identificadas con 100% de valores faltantes, dado que estas variables no presentan variabilidad ni aportan información para el análisis exploratorio ni para el entrenamiento de los modelos predictivos, fueron excluidas del dataset, esta exclusión se realizó únicamente sobre columnas totalmente vacías, conservando aquellas con valores faltantes parciales para su evaluación posterior, quedando un total de 115 variables. Posteriormente, se descartaron la variable objetivo nota, el identificador alumno y las variables sin variabilidad, variables que no aportan porque tienen un único valor en todo el dataset, como por ejemplo: tiene_cud; disc_auditiva; disc_motora; beca_fuente_provincial; beca_fuente_municipal; beca_fuente_internacional; beca_fuente_otra; beca_tipo_investigacion; trabajo_con_descuentos_jubilatorios), los campos de texto libre o alta cardinalidad y los códigos

territoriales que no debían interpretarse como variables numéricas. Bajo este criterio, se seleccionaron 81 variables candidatas para el análisis descriptivo mediante tablas cruzadas y gráficos de distribución respecto de la variable objetivo.

En la Tabla 5, se muestra un resumen de las variables que fueron descartadas por diferentes motivos.

Tabla 5: Resumen de variables para el análisis exploratorio

Tipo	Cantidad
Variable objetivo nota	1
Identificador alumno	1
Variables sin variabilidad	24
Variables de alta cardinalidad / texto libre	6
Variables numéricas usadas como códigos territoriales	2
Variables a ser analizadas en tablas cruzadas	81

Las 81 variables seleccionadas son de distinta naturaleza, esto no constituye una limitación para el análisis exploratorio, siempre que cada tipo de variable reciba un tratamiento adecuado. Las variables categóricas fueron analizadas mediante frecuencias, porcentajes y tablas cruzadas con la variable objetivo, mientras que las variables numéricas fueron evaluadas mediante estadísticas descriptivas y distribuciones. En la Tabla 6 se muestra las primeras 10 variables del ranking exploratorio inicial.

Tabla 6: Ranking exploratorio inicial

Variable	Clase con mayor diferencia	Diferencia máxima
nivel_idioma_aleman	R	45,92 pp
trabajo_ocupacion	U	43,59 pp
procedencia_piso	U	41,63 pp
nivel_idioma_ingles	A	30,54 pp
trabajo_hora_sem	U	27,78 pp
cobertura_salud	A	27,50 pp
nivel_idioma_frances	U	27,18 pp
vive_con	R	24,12 pp
situacion_madre	U	22,55 pp
cantidad_familia	U	22,36 pp

Se puede apreciar en la tabla que la variable procedencia_piso apareció muy arriba en el ranking exploratorio, esto no significa que sea una buena variable predictora. El ranking la ubicó arriba porque algunas categorías pequeñas presentan diferencias porcentuales fuertes, pero eso no implica que “vivir en un segundo piso” tenga relación con abandono o desaprobación. Por este

motivo se excluyó como predictoras a las variables de procedencia, porque contienen información muy granular del domicilio y pueden generar ruido. Las variables territoriales que sí se han conservado, pero recodificadas, dado que pueden tener un valor contextual, porque la procedencia territorial puede reflejar desigualdades de acceso, distancia, conectividad, transporte o condiciones socioeconómicas son procedencia_localidad y procedencia_codigo_postal.

El análisis exploratorio permitió identificar que algunas variables presentaban diferencias porcentuales relevantes respecto de la variable nota, aunque no todas resultaban metodológicamente adecuadas para ser consideradas predictoras. En particular, las variables asociadas al domicilio detallado del estudiante, tales como procedencia_calle, procedencia_numero, procedencia_piso, procedencia_departamento, procedencia_unidad y procedencia_barrio, fueron consideradas no pertinentes para el modelado predictivo. Si bien algunas de ellas aparecieron con diferencias importantes en el ranking exploratorio, dichas diferencias se explican principalmente por alta cardinalidad, categorías poco consistentes, valores escasos y ausencia de una justificación académica directa. Por este motivo, fueron interpretadas como fuentes potenciales de ruido y se procedió a su exclusión. En cambio, la dimensión territorial se ha conservado de manera agregada a través de variables como localidad o código postal, y fueron tratadas como categorías contextuales y no como valores numéricos continuos.

Seguidamente se han excluido las variables de campos descriptivos o de texto libre dado que tienen alta cardinalidad, muchos datos faltantes o respuestas abierta difíciles de codificar sin un tratamiento específico. Además, se ha decidido reconfigurar ciertas variables antes del modelado, las mismas se detallan en la Tabla 7. En algunos casos los datos faltantes no siempre significan "dato perdido", por ejemplo en el caso laboral, muchas veces significan "no corresponde porque el estudiante no trabaja". Por ese motivo no conviene imputarlos directamente.

Tabla 7: Variables para reconfiguración

Grupo	Variables	Decisión
Trabajo	trabajo_hace, trabajo_ocupacion, trabajo_hora_sem, trabajo_carrera	Recodificar porque los faltantes son estructurales
Idiomas	nivel_idioma_ingles, nivel_idioma_portugues, etc.	Conservar inglés; evaluar otros por baja frecuencia
Procedencia	procedencia_localidad, procedencia_codigo_postal	Agrupar territorialmente
Discapacidad / salud	condicion_discapacidad, disc_visual, es_celiaco	No usar como predictoras principales; pueden quedar para análisis descriptivo o ético
Turno	turno_preferido	Revisar porque tiene 46,52% de faltantes

Las variables tecnológicas, socioeconómicas, familiares, laborales y motivacionales fueron consideradas más adecuadas para el análisis, dado que presentan mayor coherencia conceptual con

el problema de predicción temprana del riesgo académico. Las que han sido conservadas para el análisis predictivo son las siguientes:

Tecnológicas: tecnologia_pc_casa, tecnologia_int_casa, tecnologia_int_movil tecnologia_pc_universidad, tecnologia_int_universidad.

Socioeconómicas: beca, costeo_estudios_familiar, costeo_estudios_trabajo, costeo_estudios_beca, cobertura_salud, tipo_vivienda.

Familiares y personales: situacion_padre, situacion_madre, cantidad_familia, cantidad_hijos, vive_con, estado_civil, unido_hecho.

Laborales: trabajo_existe, trabajo_recibe_pago.

Motivacionales: mot_vocacion, mot_sugerencia_familiar, mot_reconocimiento_social, mot_insercion_laboral, mot_perfil_profesional, mot_mejora_economica, mot_util_sociedad, mot_otros_p.

Hábitos: deportes, deportes_universidad, deportes_gimnasio, deportes_particular, deportes_otros.

Luego del proceso de análisis y exclusión de las variables, En la Tabla 8 se muestra el listado definitivo de variables luego del proceso de análisis y exclusión.

Tabla 8: Ranking definitivo del análisis exploratorio

Variable	Posible Interpretación
nivel_idioma_ingles	Capital cultural / formación previa
vive_con	Contexto familiar y convivencia
cantidad_familia	Composición del hogar
situacion_madre	Contexto familiar
situacion_padre	Contexto familiar
tecnologia_pc_casa	Acceso a recursos tecnológicos
tecnologia_int_casa	Acceso a conectividad
trabajo_existe	Condición laboral
costeo_estudios_trabajo	Dependencia del trabajo para sostener estudios
beca	Apoyo económico
mot_util_sociedad	Dimensión motivacional
mot_mejora_economica	Expectativa económica
mot_insercion_laboral	Motivación laboral/profesional

A partir del análisis exploratorio se realizó una selección inicial de variables para el modelado predictivo. Se excluyeron columnas completamente vacías, variables sin variabilidad, identificadores, campos de texto libre no estructurado y variables asociadas al domicilio granular del estudiante, tales como calle, número, piso, departamento, unidad y barrio. Estas últimas fueron

descartadas por presentar alta cardinalidad, codificación heterogénea y baja justificación conceptual como predictoras del rendimiento académico.

El dataset resultado del análisis exploratorio conserva valores faltantes, dado que la imputación no se aplicó directamente sobre el conjunto completo de datos para evitar fuga de información. Durante el entrenamiento, los valores faltantes fueron tratados dentro de los pipelines de preprocesamiento. Las variables numéricas se imputaron mediante la mediana calculada sobre el conjunto de entrenamiento, mientras que las variables categóricas se imputaron mediante una categoría explícita denominada "Sin dato". Posteriormente, las variables categóricas fueron codificadas mediante One-Hot Encoding. Este procedimiento permite entrenar modelos que no admiten valores faltantes de forma nativa, preservando la trazabilidad del dataset original y evitando que la información del conjunto de prueba influya en el entrenamiento.

9. Documentación del entrenamiento

Esta sección sistematiza el procedimiento de entrenamiento, validación, optimización y ajuste de umbral aplicado a los modelos Regresión Logística, Random Forest y XGBoost. La documentación está organizada según el problema de clasificación, datos utilizados, validación aplicada, imputación y codificación, estrategia de optimización, hiperparámetros evaluados, mejores parámetros y métricas obtenidas.

9.1 Datos utilizados

Los tres algoritmos fueron entrenados sobre los mismos datos, construidos a partir del dataset obtenido luego del proceso exploratorio. En todos los casos, la variable nota se utilizó únicamente para construir la variable objetivo binaria y no fue incorporada como predictora. En la Tabla 9 se muestra un resumen del conjunto de datos y en la Tabla 10 se muestra el tamaño de los datos para entrenamiento y test y la estructura de las variables para cada problema de clasificación definido.

Tabla 9: Conjunto de datos para entrenamiento

Problema	Casos incluidos	Clase 0	Clase 1	Total
A vs R+U	A, R, U	Aprobado	Desaprobado o ausente/abandono	978
A vs R	A, R	Aprobado	Desaprobado	730
A vs U	A, U	Aprobado	Ausente/abandono	527

Tabla 10: Tamaño del conjunto de datos para entrenamiento y test

Problema	Train	Test	Variables Predictoras	Variables Numéricas	Variables Categóricas
A vs R+U	733	245	77	21	56
A vs R	547	183	77	21	56
A vs U	395	132	77	21	56

9.2 Estrategia de validación

La estrategia de validación fue homogénea para todos los modelos, de modo que los resultados fueran comparables. Se utilizó una partición externa entrenamiento/validación estratificada y, sobre el conjunto de entrenamiento, se aplicó búsqueda de hiperparámetros con validación cruzada estratificada, utilizando como métrica principal el área bajo la curva ROC (ROC-AUC). Adicionalmente se calcularon las métricas de: accuracy, precisión, recall y F1-score. Posteriormente se analizaron distintos umbrales de decisión para estudiar el compromiso entre sensibilidad y cantidad de falsos positivos.

Tipo de partición	Train size	Test size	Validación cruzada	Folds	Shuffle	Random state	Métrica de optimización
Train/Test estratificado	0.75	0.25	StratifiedKFold	5	Sí	42	roc_auc

La división estratificada permitió conservar la proporción de clases en los conjuntos de entrenamiento y prueba. La optimización de hiperparámetros se realizó exclusivamente sobre el conjunto de entrenamiento; la evaluación final se efectuó sobre el conjunto de prueba independiente.

9.3 Imputación, codificación y pipeline de preprocesamiento

Como se mencionó anteriormente, el tratamiento de datos faltantes y la codificación de variables categóricas se realizó dentro del pipeline, con el fin de evitar fuga de información, ya que los valores usados para imputar se aprenden únicamente desde los datos de entrenamiento en cada partición. La siguiente tabla muestra el tratamiento de datos realizado en función del tipo de variable.

Tabla 11: Tratamiento de datos por tipo de variable

Tipo de variable	Tratamiento

Numéricas	Imputación con mediana
Numéricas	Estandarización con StandardScaler
Categóricas	Imputación con categoría explícita "Sin dato"
Categóricas	Conversión a texto
Categóricas	OneHotEncoder(handle_unknown="ignore")

Las variables numéricas fueron imputadas con la mediana y estandarizadas. Las variables categóricas fueron imputadas con una categoría explícita denominada "Sin dato", luego convertidas a texto y codificadas mediante One-Hot Encoding.

Dado que los datos presentan distintos grados de desbalance entre clases, se incorporó una estrategia de balanceo basada en ponderación de clases. Para ello, durante la optimización de hiperparámetros se evaluaron dos configuraciones: sin ponderación de clases (class_weight = None) y con ponderación automática inversamente proporcional a la frecuencia de las clases (class_weight = "balanced"). Esta estrategia permite penalizar con mayor intensidad los errores sobre la clase minoritaria sin modificar la distribución original de los datos mediante técnicas de remuestreo.

9.4 Algoritmo: Regresión Logística

Como punto de partida se utilizó la Regresión Logística como modelo base por su interpretabilidad y por permitir una comparación inicial con modelos más complejos.

El modelo se entrenó sobre los tres problemas: A vs R+U, A vs R y A vs U. Con los tamaños de entrenamiento y prueba indicados anteriormente. Se aplicó validación estratificada sobre los datos de entrenamiento y testeo estratificado 75/25. Sobre el conjunto de entrenamiento se utilizó GridSearchCV con StratifiedKFold de 5 particiones. La métrica usada para seleccionar la mejor configuración fue el área bajo la curva ROC-AUC. Se utilizó el pipeline común de preprocesamiento: imputación con mediana y escalado para variables numéricas; imputación con "Sin dato" y One-Hot Encoding para variables categóricas. La Tabla 12 muestra las estrategias de optimización y los hiperparámetros probados.

Tabla 12: Estrategias de optimización e hiperparámetros utilizados para el modelo de regresión logística

Elemento	**Valor**
Modelo	Regresión Logística
Estrategia de optimización	GridSearchCV

Validación interna	StratifiedKFold con 5 particiones
Métrica de selección	roc_auc
Hiperparámetro C	[0.01, 0.1, 1, 10]
Hiperparámetro penalty	['l2']
Hiperparámetro solver	['lbfgs']
Hiperparámetro class_weight	[None, 'balanced']

La Tabla 13, muestra los valores de los parámetros con los que el modelo arrojó los mejores resultados para cada uno de los problemas de clasificación.

Tabla 13: Valores de los parámetros para el mejor resultado

Problema	**Hiperparámetro C**	**Regularización**	**Solver**	**Class weight**
A vs R+U	10	l2	lbfgs	None
A vs R	0.0100	l2	lbfgs	balanced
A vs U	0.0100	l2	lbfgs	balanced

En la Tabla 14 se muestran las métricas obtenidas con un umbral de 0,50.

Tabla 14: valores de las métricas para el algoritmo de regresión logística

Problema	**CV ROC-AUC**	**Accuracy**	**Precision**	**Recall**	**F1**	**Test ROC-AUC**
A vs R+U	0.6216	0.6939	0.7525	0.8514	0.7989	0.6342
A vs R	0.6293	0.6612	0.7742	0.6372	0.6990	0.7013
A vs U	0.6201	0.5833	0.5814	0.4032	0.4762	0.6172

9.5 Algoritmo: Random Forest

Random Forest es un modelo de ensamble basado en árboles de decisión, se ha decidido utilizarlo dado que permite capturar relaciones no lineales e interacciones entre variables. El modelo se entrenó sobre los tres problemas definidos: A vs R+U, A vs R y A vs U. Los tamaños de entrenamiento y prueba fueron los indicados anteriormente. Se aplicó etrenamiento/test estratificado 75/25. Sobre el conjunto de entrenamiento se utilizó GridSearchCV con StratifiedKFold de 5 particiones. La métrica usada para seleccionar la mejor configuración fue ROC-AUC.

Se utilizó el pipeline común de preprocesamiento: imputación con mediana y escalado para variables numéricas; imputación con "Sin dato" y One-Hot Encoding para variables categóricas. Las estrategias de optimización e hiperparámetros probados son los que se indican en la Tabla 15.

Tabla 15: Estrategias y valores de hiperparámetros usuados en random forest

Elemento	**Valor**
Modelo	Random Forest
Estrategia de optimización	GridSearchCV
Validación interna	StratifiedKFold con 5 particiones
Métrica de selección	roc_auc
Hiperparámetro n_estimators	[100, 300]
Hiperparámetro max_depth	[None, 5, 10]
Hiperparámetro min_samples_split	[2, 5]
Hiperparámetro min_samples_leaf	[1, 3]
Hiperparámetro class_weight	[None, 'balanced']

La Tabla 16 muestra los parámetros obtenidos que arrojaron los mejores resultados para cada uno de los problemas en el modelo random forest.

Tabla 16: Valores de hiperparámetros que arrojan el mejor resultado

Problema	**n_estimators**	**max_depth**	**min_samples_split**	**min_samples_leaf**	**class_weight**
A vs R+U	300	None	2	1	balanced
A vs R	300	None	2	1	None

A vs U	300	None	2	1	None

A continuación, en Tabla 17, se pueden ver los valores obtenidos para cada métricas aplicando un umbral de 0,50 en el entrenamiento del modelo random forest.

Tabla 17: Valores de las métricas para el umbral de 0,50

Problema	CV ROC-AUC	Accuracy	Precision	Recall	F1	Test ROC-AUC
A vs R+U	0.6476	0.7143	0.7966	0.8057	0.8011	0.6797
A vs R	0.6140	0.6995	0.7197	0.8407	0.7755	0.7216
A vs U	0.7185	0.7197	0.6984	0.7097	0.7040	0.7402

9.6 Algoritmo: XGBoost

XGBoost se utilizó como modelo de boosting de árboles de decisión. Construye árboles en forma secuencial para corregir errores de modelos anteriores. El modelo se entrenó sobre los tres problemas de clasificación: A vs R+U, A vs R y A vs U. Los tamaños de entrenamiento y prueba son los indicados anteriormente. La validación fue la misma que se aplicó a los otros dos modelos. La métrica usada para seleccionar la mejor configuración fue ROC-AUC. Se utilizó el pipeline común de preprocesamiento: imputación con mediana y escalado para variables numéricas; imputación con "Sin dato" y One-Hot Encoding para variables categóricas. Las estrategias de optimización e hiperparámetros probados son los que se indican en la Tabla 18.

Tabla 18: Estrategias de optimización utilizadas en el modelo XGBoost

Elemento	Valor
Modelo	XGBoost
Estrategia de optimización	GridSearchCV
Validación interna	StratifiedKFold con 5 particiones
Métrica de selección	roc_auc
Hiperparámetro n_estimators	[100, 300]
Hiperparámetro learning_rate	[0.05, 0.1]
Hiperparámetro max_depth	[3, 5]

Hiperparámetro subsample	[0.8, 1.0]
Hiperparámetro colsample_bytree	[0.8, 1.0]
Hiperparámetro scale_pos_weight	[1, valor balanceado calculado por vista]

La Tabla 19 muestra los parámetros obtenidos que arrojaron los mejores resultados para cada uno de los problemas en el modelo XGBoost y en la Tabla 20, se puede observar los valores de las métricas obtenidas con un umbral de 0,50.

Tabla 19: parámetros que arrojaron los mejores resultados

Problema	n_estimators	learning_rate	max_depth	subsample	colsample_bytree	scale_pos_weight
A vs R+U	300	0.1000	5	1	1	1
A vs R	300	0.0500	5	0.8000	0.8000	0.6183
A vs U	300	0.1000	5	0.8000	0.8000	1.1237

Tabla 20: Valores de las métricas para un umbral de 0,50

Problema	CV ROC-AUC	Accuracy	Precision	Recall	F1	Test ROC-AUC
A vs R+U	0.6337	0.7347	0.7806	0.8743	0.8248	0.6708
A vs R	0.6164	0.6995	0.7544	0.7611	0.7577	0.6948
A vs U	0.7096	0.6742	0.6508	0.6613	0.6560	0.6930

10. Ajuste del umbral de decisión

Luego del entrenamiento y optimización inicial, se evaluaron distintos umbrales de decisión: 0.50, 0.45, 0.40, 0.35, 0.30 y 0.25. El ajuste de umbral no modifica el entrenamiento del modelo; solo cambia la regla con la que una probabilidad estimada se transforma en una de las clases binarias. La regla aplicada fue: si P(riesgo) es mayor o igual al umbral, entonces el caso se clasifica como clase 1; en caso contrario, como clase 0.

En un sistema de alerta temprana, la métrica central no es solo la exactitud, sino especialmente el recall de la clase de riesgo y la reducción de falsos negativos, ya que un falso negativo representa un estudiante en riesgo no detectado. Las configuraciones recomendadas considerando un recall

mínimo y un desempeño operativo se muestran en la Tabla 21. Las configuraciones recomendadas considerando las mejores combinaciones por F1-score son las que se muestran en la Tabla 22.

Tabla 21: Configuraciones recomendadas considerando un recall mínimo y un desempeño operativo.

Problema	Modelo	Umbral	Accuracy	Precision	Recall	F1	ROC-AUC	FN	FP
A vs R	Random Forest	0.5000	0.6995	0.7197	0.8407	0.7755	0.7216	18	37
A vs R+U	Random Forest	0.2500	0.7510	0.7664	0.9371	0.8432	0.6797	11	50
A vs U	Random Forest	0.3500	0.6591	0.6000	0.8226	0.6939	0.7402	11	34

Tabla 22: Configuraciones recomendadas considerando las mejores combinaciones por F1-score.

Problema	Modelo	Umbral	Accuracy	Precision	Recall	F1	ROC-AUC	FN	FP
A vs R	Random Forest	0.5000	0.6995	0.7197	0.8407	0.7755	0.7216	18	37
A vs R+U	Random Forest	0.2500	0.7510	0.7664	0.9371	0.8432	0.6797	11	50
A vs U	Random Forest	0.5000	0.7197	0.6984	0.7097	0.7040	0.7402	18	19

Como síntesis de las diferentes combinaciones de parámetros y ajustes de los modelos, se muestra en la Tabla 23 una comparación final.

Tabla 23: Comparación final del ajuste del umbral de decisión.

Problema	Mejor modelo por ROC-AUC	Modelo operativo recomendado	Motivo
A vs R+U	Random Forest	Random Forest, umbral 0.25	Mejora recall y F1; reduce FN de 34 a 11

A vs R	Random Forest	Random Forest, umbral 0.50	Mejor equilibrio; bajar el umbral no mejora F1
A vs U	Random Forest	Random Forest, umbral 0.35	Reduce FN de 18 a 11 y eleva el recall a 0.8226

11. Resultados

Se evaluaron algoritmos supervisados ampliamente utilizados en problemas de clasificación, la selección de estos modelos responde a su capacidad para manejar conjuntos de datos heterogéneos, variables categóricas y relaciones no lineales entre atributos.

Ante el desbalance observado entre las clases, se analizaron estrategias de tratamiento: En Regresión Logística y Random Forest se utilizó el hiperparámetro class_weight con dos opciones, sin balanceo de clases (none) y con ponderación automática inversamente proporcional a la frecuencia de clases (balanced). La estrategia de balanceo fue, por tanto: ponderación automática de clases mediante class_weight. En XGBoost se utilizó el hiperparámetro scale_pos_weight, evaluando tanto el valor 1, equivalente a no aplicar ponderación diferencial, como un valor balanceado calculado para cada problema a partir de la relación entre la cantidad de casos de la clase 0 y la clase 1. Este parámetro ajusta el peso de la clase positiva, se han probado dos parámetros para cada problema: 1: sin ponderación diferencial y valor balanceado: ponderación calculada según la relación entre clases (scale_pos_weight = cantidad de clase 0 / cantidad de clase 1; como la clase 1 representa el riesgo, este valor ajusta el peso de esa clase en función del desbalance observado en cada vista).

Cada estrategia fue evaluada independientemente para determinar su impacto sobre el desempeño predictivo.

Los tres algoritmos fueron entrenados mediante pipelines de preprocesamiento y optimizados con GridSearchCV usando validación cruzada estratificada. Random Forest obtuvo el mejor comportamiento general en los tres problemas de clasificación binaria cuando se considera ROC-AUC y desempeño operativo. Para el problema A vs R+U, Random Forest con umbral 0.25 mejoró el recall y el F1-score, reduciendo los falsos negativos de 34 a 11 respecto del umbral estándar. Para el problema A vs R, Random Forest con umbral 0.50 presentó el mejor equilibrio entre precision, recall y F1-score; disminuir el umbral no produjo una mejora sustantiva. Para el problema A vs U, Random Forest con umbral 0.35 resulta conveniente para alerta temprana porque reduce los falsos negativos de 18 a 11 y aumenta el recall a 0.8226.

La Regresión Logística se posicionó como línea base interpretable, mientras que XGBoost mostró resultados competitivos, especialmente en recall para la vista global.

A continuación, se presentan los datos obtenidos como resultado general de cada problema de clasificación. En la Tabla 24 se muestran los resultados de Riesgo académico global (A vs RU). En la Tabla 25, se muestran los resultados de Riesgo de desaprobación (A vs R). En Tabla 26 se muestran los resultados de Riesgo de abandono / ausencia (A vs U).

Tabla 24: Resultado general de riesgo académico global.

Modelo	CV ROC-AUC	Test ROC-AUC	Accuracy	Precision	Recall	F1
Regresión Logística	0.6216	0.6342	0.6939	0.7525	0.8514	0.7989
Random Forest	0.6476	0.6797	0.7143	0.7966	0.8057	0.8011
XGBoost	0.6337	0.6708	0.7347	0.7806	0.8743	0.8248

Si el objetivo principal es detectar estudiantes en riesgo, XGBoost es muy atractivo porque identifica más casos positivos. Si el criterio principal es la capacidad discriminativa global medida por ROC-AUC, Random Forest queda primero. También hay que tener especial atención con accuracy, en este problema la clase de riesgo R+U es mayoritaria, por lo que una accuracy cercana a 0.71 puede no ser tan informativa, es por ello que conviene priorizar ROC-AUC, recall y matriz de confusión.

Tabla 25: Resultado general de riesgo de desaprobación.

Modelo	CV ROC-AUC	Test ROC-AUC	Accuracy	Precision	Recall	F1
Regresión Logística	0.6293	0.7013	0.6612	0.7742	0.6372	0.6990
Random Forest	0.6140	0.7216	0.6995	0.7197	0.8407	0.7755
XGBoost	0.6164	0.6948	0.6995	0.7544	0.7611	0.7577

Para este problema se puede ver que el mejor modelo en test es Random Forest, dado que presenta un ROC-AUC = 0.7216, como así también obtiene el mayor recall = 0.8407, y el mayor F1 = 0.7755.

Tabla 26: Resultado general de riesgo de ausencia/abandono.

Modelo	CV ROC-AUC	Test ROC-AUC	Accuracy	Precision	Recall	F1
Regresión Logística	0.6201	0.6172	0.5833	0.5814	0.4032	0.4762
Random Forest	0.7185	0.7402	0.7197	0.6984	0.7097	0.7040
XGBoost	0.7096	0.6930	0.6742	0.6508	0.6613	0.6560

Se puede apreciar que para este problema Random Forest es el mejor modelo, presenta el mejor valor en todas las métricas principales: ROC-AUC = 0.7402, Accuracy = 0.7197, Recall = 0.7097 y F1 = 0.704.

Luego de analizar el comportamiento de cada modelo entrenado en cada problema de clasificación se presenta en la Tabla 27 el mejor modelo para cada problema de clasificación.

Tabla 27:Mejor modelo para cada problema de clasificación.

Problema	Mejor modelo por ROC-AUC test	ROC-AUC test
A vs R+U	Random Forest	0.6797
A vs R	Random Forest	0.7216
A vs U	Random Forest	0.7402

En la Tabla 28 se puede ver una comparación por estabilidad entre validación cruzada y test, comparando el ROC-AUC obtenido en validación cruzada con el ROC-AUC obtenido en test.

Tabla 28: Comparación por estabilidad entre validación cruzada y test.

Problema	Modelo	CV ROC-AUC	Test ROC-AUC	Diferencia
A vs R+U	Regresión Logística	0.6216	0.6342	+0.0126
A vs R+U	Random Forest	0.6476	0.6797	+0.0321
A vs R+U	XGBoost	0.6337	0.6708	+0.0371
A vs R	Regresión Logística	0.6293	0.7013	+0.0720
A vs R	Random Forest	0.6140	0.7216	+0.1076
A vs R	XGBoost	0.6164	0.6948	+0.0784
A vs U	Regresión Logística	0.6201	0.6172	-0.0029
A vs U	Random Forest	0.7185	0.7402	+0.0217
A vs U	XGBoost	0.7096	0.6930	-0.0166

Los resultados muestran que Random Forest presentó el mejor desempeño global entre los modelos evaluados, alcanzando el mayor ROC-AUC en los tres problemas de clasificación. Para el problema de riesgo académico global obtuvo un ROC-AUC de 0.6797, en el problema de desaprobación un ROC-AUC de 0.7216 y en el problema de abandono/ausencia un ROC-AUC de 0.7402. Este último caso mostró el comportamiento más sólido, tanto por el valor de ROC-AUC como por la consistencia entre validación cruzada y evaluación sobre el conjunto de prueba.

La Regresión Logística permitió establecer una línea base interpretable, aunque con menor rendimiento predictivo. XGBoost presentó resultados competitivos, especialmente en la vista global, donde alcanzó el mayor recall y F1-score, aunque no superó a Random Forest en ROC-AUC. Estos resultados sugieren que los modelos basados en árboles de decisión resultan más adecuados para capturar las relaciones no lineales e interacciones presentes en el dataset.

También se observa que el problema de abandono/ausencia parece ser más separable que el problema de riesgo global, posiblemente porque la vista global combina situaciones académicas diferentes, como desaprobación y ausencia/abandono. Por ello, resulta metodológicamente pertinente mantener los tres problemas diferenciados.

Poner aquí la tabla matriz de confusión

12. Discusión y Conclusiones

El trabajo presentó un enfoque basado en técnicas de aprendizaje automático para la identificación temprana de estudiantes en riesgo académico en asignaturas críticas del primer año de Ingeniería en Sistemas de la UNCAus.

Los resultados muestran que Random Forest constituye la alternativa más adecuada para la predicción de riesgo académico global y desaprobación, mientras que XGBoost representa una buena opción para la identificación de estudiantes con riesgo de abandono.

La utilización de distintos umbrales de decisión permitió analizar el compromiso existente entre sensibilidad y precisión. Desde una perspectiva institucional, la priorización del recall resulta razonable debido al elevado costo asociado a no detectar estudiantes en riesgo. Sin embargo, esta decisión implica un incremento en la cantidad de falsos positivos, aspecto que debe ser considerado durante la implementación práctica del sistema.

Debido a que los modelos incorporan variables socioeconómicas, familiares y geográficas, existe el riesgo potencial de reproducir desigualdades presentes en los datos históricos. Por esta razón, los resultados obtenidos no deben utilizarse para la toma automática de decisiones académicas ni para la clasificación permanente de estudiantes. Su finalidad consiste exclusivamente en asistir a docentes y responsables institucionales en la identificación temprana de situaciones de vulnerabilidad académica que requieran acompañamiento pedagógico.

La desaprobación y el riesgo académico global mostraron desempeños moderados, se espera que, al incluir otras variables relacionadas con aspectos puramente académicos, por ejemplo: notas obtenidas en los trabajos y parciales, tiempo dedicado al estudio, etc. los resultados sean más favorables. La predicción de abandono alcanzó los mejores resultados, sugiriendo la existencia de patrones más claramente identificables asociados a la desvinculación temprana.

Como trabajo futuro se propone ampliar el conjunto de datos, incorporar nuevas cohortes académicas y variables relacionadas con el desempeño.

Referencias

Albreiki, B., Zaki, N., y Alashwal, H. (2021). A systematic literature review of predicting student performance using machine learning techniques. IEEE Access, 9, 41803-41829.

Baashar, Y., Alkawsi, G., Ali, N. A., Alhussian, H., y Bahbouh, H. T. (2021). Predicting student's performance using machine learning methods: A systematic literature review. 2021 International Conference on Computer & Information Sciences (ICCOINS), 1–6. https://doi.org/10.1109/ICCOINS49675.2021.9515151

Bennedsen, J., y Caspersen, M. E. (2019). Failure rates in introductory programming. ACM SIGCSE Bulletin, 51(2), 32-38. https://doi.org/10.1145/3328334.3328343.

Bernardo, A. B., Esteban, M., Fernández, E., Cervero, A., Tuero, E., y Solano, P. (2016). Variables predictoras del abandono universitario: el papel de la orientación profesional y la interacción con el profesor. Psicothema, 28(1), 46-52.

Cortez, P., y Silva, A. (2008). Using data mining to predict secondary school student performance. In Proceedings of the 5th Future Business Technology Conference (pp. 5–12).

Dekker, G. W., Pechenizkiy, M., y Vleeshouwers, J. M. (2009). Predicting students drop out: A case study. Proceedings of the International Conference on Educational Data Mining, 41–50.

Kotsiantis, S. B. (2012). Use of machine learning techniques for educational data mining. Journal of Educational Computing Research, 7(2), 469-485.

La Red Martínez, D. L., Karanik, M., Giovannini, M. E., y Scappini, R. (2016). Towards a predictive model of academic performance using data mining in the UTN-FRRe. Journal of Systemics, Cybernetics and Informatics, 14(2), 36–41.

Romero, C., y Ventura, S. (2020). Educational data mining and learning analytics: An updated survey. WIREs Data Mining and Knowledge Discovery, 10(3), e1355.

Seymour, E., y Hunter, A. B. (Eds.). (2020). Talking about Leaving Revisited: Persistence, Relocation, and Loss in Undergraduate STEM Education. Springer Nature. https://doi.org/10.1007/978-3-030-25304-2